


# 모두를 위한 딥러닝 (이미지처리편)

경북대학교 IT교육센터

허 찬

| 차시(모듈) | 차시별 주제                     | 학습내용                                                            |
|--------|----------------------------|-----------------------------------------------------------------|
| 1      | 딥러닝을 이용한 이미지 처리            | 이미지 처리의 이해<br>다양한 이미지처리의 응용 분야에 대한 이해                           |
| 2      | 특징 추출의 이해                  | 이미지 데이터 전처리 기법의 이해<br>이미지 특징 추출의 이해 및 실습<br>딥러닝을 이용한 학습 및 추론 과정 |
| 3      | Convolution Neural Network | 합성곱 신경망의 이해                                                     |
| 4      | CNN 모델의 이해                 | 다양한 CNN 모델의 이해<br>딥러닝의 여러가지 요소                                  |
| 5      | CNN을 이용한 분류 모델 실습          | CNN을 이용한 이미지 분류 모델 실습                                           |
| 6      | 전이 학습 모델의 이해               | 전이 학습의 이해<br>전이학습을 이용한 이미지 처리 모델 실습                             |
| 7      | 객체 인식 모델의 이해               | 다양한 객체 인식 모델의 이해 (Yolo, RCNN 등)                                 |
| 8      | Transformer 기반 이미지 처리 모델 1 | Attention과 Transformer의 이해                                      |
| 9      | Transformer 기반 이미지 처리 모델 2 | Transformer 기반 이미지 처리 모델 (ViT)의 이해                              |
| 10     | 이미지 생성 모델의 이해              | 최신 이미지 생성 모델의 이해<br>오토인코더의 이해 및 실습                              |
| 11     | 최신 이미지 처리 기술의 이해           | 최신 컴퓨터비전 모델의 이해<br>비디오 처리의 이해                                   |

# NLP의 발전 with 기계번역



영어 ▾

↔ 한국어 ▾

요약

용어집

×

Cross encoders tend to capture richer information than dual encoders due to their deeper cross-modal interaction. Thus, we further add a distillation loss to the architecture by distilling the image-text matching scores from the cross encoder to the dual encoder. As distillation for image-text retrieval has rarely been explored, in this work, we put our focus on the designs of this distillation objective and present comprehensive ablations around it. We first examine how to construct the score distributions for the distillation between the two architectures. The standard distillation objective [25] is designed for classification tasks and requires a teacher score distribution as input. To extend the distillation for image-text retrieval, we follow [50] to construct a set of negatives for each positive pair. In [50], all in-batch negatives are used, and only a single distribution for each image-text pair is constructed (from a text to its image negatives). In our study, we find that distillation can be effective with a few hard negatives, and that both image negatives and text negatives are useful. These findings lead to a more efficient distillation objective for image-text retrieval.

크로스 인코더는 모달 간 상호 작용이 더 깊기 때문에 듀얼 인코더보다 더 풍부한 정보를 캡처하는 경향이 있습니다. 따라서 크로스 인코더에서 듀얼 인코더로 이미지-텍스트 매칭 점수를 증류하여 아키텍처에 증류 손실을 추가합니다. 이미지-텍스트 검색을 위한 증류는 거의 연구되지 않았기 때문에 이 작업에서는 이 증류 목표의 설계에 초점을 맞추고 이에 대한 포괄적인 제거 방법을 제시합니다. 먼저 두 아키텍처 간의 증류에 대한 점수 분포를 구성하는 방법을 살펴봅니다. 표준 증류 목표[25]는 분류 작업을 위해 설계되었으며 교사 점수 분포를 입력으로 필요로 합니다. 이미지-텍스트 검색을 위한 증류를 확장하기 위해 [50]을 따라 각 포지티브 쌍에 대해 네거티브 세트를 구성합니다. [50]에서는 모든 배치 내 네거티브가 사용되며, 각 이미지-텍스트 쌍에 대해 단 하나의 분포만 구성됩니다(텍스트에서 이미지 네거티브까지). 본 연구에서는 몇 개의 하드 네거티브를 사용하면 증류가 효과적일 수 있으며 이미지 네거티브와 텍스트 네거티브 모두 유용하다는 것을 발견했습니다. 이러한 발견은 이미지-텍스트 검색을 위한 보다 효율적인 증류 목표에 이르게 합니다.

🔊 ↶ ↷


1203 / 5000

🔊

👍 👎 📄 🔗

...


# 빠르게 달려왔습니다, 딥러닝&인공지능 10년



- 딥러닝 연구가 주목받고 10년, 생성형 AI의 등장

<https://towardsdatascience.com/ten-years-of-ai-in-review-85decdb2a540>

# NLP의 발전 with 기계번역



- 생성 모델을 위한 10년간의 여정

## 8.1 Seq2seq model

---

### Sequence to Sequence Learning with Neural Networks

---

Ilya Sutskever  
Google  
ilyasu@google.com

Oriol Vinyals  
Google  
vinyals@google.com

Quoc V. Le  
Google  
qvl@google.com



#### Abstract

Deep Neural Networks (DNNs) are powerful models that have achieved excellent performance on difficult learning tasks. Although DNNs work well whenever large labeled training sets are available, they cannot be used to map sequences to sequences. In this paper, we present a general end-to-end approach to sequence learning that makes minimal assumptions on the sequence structure. Our method uses a multilayered Long Short-Term Memory (LSTM) to map the input sequence to a vector of a fixed dimensionality, and then another deep LSTM to decode the target sequence from the vector. Our main result is that on an English to French translation task from the WMT-14 dataset, the translations produced by the LSTM achieve a BLEU score of 34.8 on the entire test set, where the LSTM's BLEU score was penalized on out-of-vocabulary words. Additionally, the LSTM did not have difficulty on long sentences. For comparison, a phrase-based SMT system achieves a BLEU score of 33.3 on the same dataset. When we used the LSTM to rerank the 1000 hypotheses produced by the aforementioned SMT system, its BLEU score increases to 36.5, which is close to the previous state of the art. The LSTM also learned sensible phrase and sentence representations that are sensitive to word order and are relatively invariant to the active and the passive voice. Finally, we found that reversing the order of the words in all source sentences (but not target sentences) improved the LSTM's performance markedly, because doing so introduced many short term dependencies between the source and the target sentence which made the optimization problem easier.

Sequence to Sequence Learning with Neural Networks (2014,NIPS)


## 8.1 Seq2seq model

### Sequence to Sequence model



# 8.1 Seq2seq model

## Sequence to Sequence model




|         |       |
|---------|-------|
| I       | 0.157 |
|         | -0.25 |
|         | 0.478 |
|         | -0.78 |
| am      | 0.78  |
|         | 0.29  |
|         | -0.96 |
|         | 0.52  |
| a       | 0.75  |
|         | -0.81 |
|         | 0.96  |
|         | 0.12  |
| student | 0.88  |
|         | -0.17 |
|         | 0.29  |
|         | 0.48  |



## 8.1 Seq2seq model

### Sequence to Sequence model



- 컨텍스트 벡터는 인코더에서의 마지막 RNN 셀의 은닉 상태값, 이는 입력 문장의 모든 단어 토큰들의 정보를 요약.
- 디코더는 인코더의 마지막 RNN 셀의 은닉 상태인 컨텍스트 벡터를 첫번째 은닉 상태의 값으로 사용. 디코더의 첫번째 RNN 셀은 이 첫번째 은닉 상태의 값과, 현재  $t$ 에서의 입력값인 `<sos>`로부터, 다음에 등장할 단어를 예측.
- 이 예측된 단어는 다음 시점인  $t+1$  RNN에서의 입력값이 되고, 이  $t+1$ 에서의 RNN 또한 이 입력값과  $t$ 에서의 은닉 상태로부터  $t+1$ 에서의 출력 벡터. 즉, 또 다시 다음에 등장할 단어를 예측.
- 출력 단어로 나올 수 있는 단어들은 다양한 단어들이 있으며 seq2seq 모델은 선택될 수 있는 모든 단어들로부터 하나의 단어를 골라서 예측.

## 8.1 Seq2seq model

### Sequence to Sequence – 한계점

- 하나의 고정된 크기의 Context vector에 모든 정보를 압축하려고 하니까 정보 손실이 발생
- RNN의 고질적인 문제점인 Vanishing Gradient 문제
- 입력 문장이 길면 번역 품질이 떨어지는 현상

# Attention model의 등장

## Attention model

- 딥러닝 모델이 특정 벡터에 주목하게 만들어 모델의 성능을 높이는데 사용
- “중요한 부분에 집중하게 만들자” 는 핵심 아이디어.
- 현 딥러닝 중 가장 많이 사용되고 인기있는 아이디어중 하나

### NEURAL MACHINE TRANSLATION BY JOINTLY LEARNING TO ALIGN AND TRANSLATE

**Dzmitry Bahdanau**  
Jacobs University Bremen, Germany

**KyungHyun Cho**   **Yoshua Bengio\***  
Université de Montréal

#### ABSTRACT

Neural machine translation is a recently proposed approach to machine translation. Unlike the traditional statistical machine translation, the neural machine translation aims at building a single neural network that can be jointly tuned to maximize the translation performance. The models proposed recently for neural machine translation often belong to a family of encoder-decoders and encode a source sentence into a fixed-length vector from which a decoder generates a translation. In this paper, we conjecture that the use of a fixed-length vector is a bottleneck in improving the performance of this basic encoder-decoder architecture, and propose to extend this by allowing a model to automatically (soft-)search for parts of a source sentence that are relevant to predicting a target word, without having to form these parts as a hard segment explicitly. With this new approach, we achieve a translation performance comparable to the existing state-of-the-art phrase-based system on the task of English-to-French translation. Furthermore, qualitative analysis reveals that the (soft-)alignments found by the model agree well with our intuition.

NEURAL MACHINE TRANSLATION BY JOINTLY LEARNING TO ALIGN AND TRANSLATE (ICLR 2015)

## 8.2 Seq2seq model + attention model

---

Published as a conference paper at ICLR 2015

---

### NEURAL MACHINE TRANSLATION BY JOINTLY LEARNING TO ALIGN AND TRANSLATE

**Dzmitry Bahdanau**

Jacobs University Bremen, Germany

**Kyunghyun Cho**   **Yoshua Bengio\***


Université de Montréal

#### ABSTRACT

Neural machine translation is a recently proposed approach to machine translation. Unlike the traditional statistical machine translation, the neural machine translation aims at building a single neural network that can be jointly tuned to maximize the translation performance. The models proposed recently for neural machine translation often belong to a family of encoder-decoders and encode a source sentence into a fixed-length vector from which a decoder generates a translation. In this paper, we conjecture that the use of a fixed-length vector is a bottleneck in improving the performance of this basic encoder-decoder architecture, and propose to extend this by allowing a model to automatically (soft-)search for parts of a source sentence that are relevant to predicting a target word, without having to form these parts as a hard segment explicitly. With this new approach, we achieve a translation performance comparable to the existing state-of-the-art phrase-based system on the task of English-to-French translation. Furthermore, qualitative analysis reveals that the (soft-)alignments found by the model agree well with our intuition.

## 8.2 Seq2seq model + attention model

### Seq2Seq + attention model



**Attention(Q, K, V) = Attention Value**

Q = Query : t-1 시점의 디코더 셀에서의 은닉 상태


K = Keys : 모든 시점의 인코더 셀의 은닉 상태들

V = Values : 모든 시점의 인코더 셀의 은닉 상태들

# 8.2 Seq2seq model + attention model

## Seq2Seq + attention model

1) 어텐션 스코어(Attention Score)를 구한다.



$$s_{t-1}^T \times h_i$$

s(t): 디코더의 t시점의 은닉상태

Attention value

$$s_t = f(s_{t-1}, y_{t-1}, a_t)$$


$$score(s_{t-1}, h_i) = s_{t-1}^T h_i$$

$$e^t = [s_{t-1}^T h_1, \dots, s_{t-1}^T h_N]$$

## 8.2 Seq2seq model + attention model

### Seq2Seq + attention model

2) 소프트맥스(softmax) 함수를 통해 어텐션 분포(Attention Distribution)를 구한다.




$$\alpha^t = \text{softmax}(e^t)$$

## 8.2 Seq2seq model + attention model

### Seq2Seq + attention model

3) 각 인코더의 어텐션 가중치와 은닉 상태를 가중합하여 어텐션 값(Attention Value)을 구한다.

Attention Value  $a_t$




$$a_t = \sum_{i=1}^N \alpha_i^t h_i$$



## 8.2 Seq2seq model + attention model

### Seq2Seq + attention model

4) 어텐션 값과 디코더의 t-1 시점의 은닉 상태를 결합한다.(Concatenate)



$$s_t = f(s_{t-1}, y_{t-1}, a_t)$$

$$s_t = f(v_t, y_{t-1})$$

은닉층 :  $h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$

출력층 :  $y_t = f(W_y h_t + b)$

## 8.2 Seq2seq model + attention model

### Seq2Seq + attention model - 한계점

- 단순히 하나의 벡터에 인코더 부분에 해당하는 문장에 대한 모든 정보를 담고있어 문장안의 개별 단어와의 관계를 확인하기 어렵다.
- 문장 길이가 길수록 모든 정보를 하나의 벡터에 포함하기에는 부족하다는 단점이 있다.

# 인공지능 역사상 가장 위대한 모델 - Transformer

## Transformer model

### Attention Is All You Need

Ashish Vaswani\*  
Google Brain  
avaswani@google.com

Noam Shazeer\*  
Google Brain  
noam@google.com

Niki Parmar\*  
Google Research  
nikip@google.com

Jakob Uszkoreit\*  
Google Research  
usz@google.com

Llion Jones\*  
Google Research  
llion@google.com

Aidan N. Gomez\* †  
University of Toronto  
aidan@cs.toronto.edu


Lukasz Kaiser\*  
Google Brain  
lukaszkaier@google.com

Illia Polosukhin\* ‡  
illia.polosukhin@gmail.com

#### Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer,

Google 번역




Attention is all you need (2017,NIPS)

- 이러한 순환 신경망 기반의 시퀀스 투 시퀀스 모델의 한계를 지적하고 극복한 모델이 Transformer.
- 2017년 구글이 발표한 논문인 "Attention is all you need"에서 나온 모델로 기존의 seq2seq의 구조인 인코더-디코더를 따르면서도, 논문의 이름처럼 어텐션 (Attention)만으로 구현한 모델.
- RNN은 쓰지 않고 어텐션만을 사용하여 인코더-디코더 구조를 만들어 **학습 속도가 무척 빠르다**는 장점을 갖고 있으며 성능도 RNN보다 우수.
- Rnn계열보다 30배이상 연산속도가 빨라 실제 웹상에서 쓰는 구글번역기에서도 차용된 모델.

## 8.3 Transformer model



### Transformer model




- Attention을 RNN의 보정을 위한 용도가 아니라 아예 어텐션으로 인코더와 디코더를 만들어보면 어떨까?

## 8.3 Transformer model


### Transformer model



## 8.3 Transformer model





<RNN + attention>



<Only Attention>


# 8.3 Transformer model

## Transformer – Encoder : Positional encoding



$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}})$$


$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$



순서정보를 주는 과정

## 8.3 Transformer model

### Transformer – Encoder : Attention mechanism




1. attention 구조가 한 개가 아닌 여러 번의 어텐션이 병렬로 연결된 구조
2. Self attention > Scaled dot-product attention > Multi-head attention

Self-attention : 입력 토큰간의 관계를 이해하는 매커니즘.



## 8.3 Transformer model

### Transformer model – Self attention




- 셀프 어텐션은 입력 문장 내의 단어들끼리 유사도를 구하고 그것(it)이 동물(animal)과 연관되었을 확률이 높다는 것을 찾아낼 수 있음.

*What means it?*

**Self-attention** : 입력 토큰간의 관계를 이해하는 매커니즘.

## 8.3 Transformer model

### Transformer model – Multi-head attention




As we encode the word "it", one attention head is focusing most on "the animal", while another is focusing on "tired" -- in a sense, the model's representation of the word "it" bakes in some of the representation of both "animal" and "tired".

- 2head를 사용하여 2개의 다른 어텐션이 들어간 예시.
- 첫번째 어텐션은 애니멀에 포커스를 상당히 맞췄고 두번째 어텐션에서는 tire에 상당히 초점을 맞춤.
- 다양한 가중치를 가진 (여러 시각에서의) 어텐션을 이용하여 각 토큰간의 관계를 파악해보자.
- 이를 여러 관점에서 수집하여 이러한 정보를 보완.

## 8.3 Transformer model


### Transformer – Position-wise Feed forward network



- **FFN(Feed-Forward Network)**은 셀프 어텐션 계층 다음에 오는 중요한 부분.
- 트랜스포머의 각 층에 존재하며, 셀프 어텐션을 통해 얻은 정보를 추가적으로 처리하는 역할.
- FFN은 입력된 데이터를 더 복잡하고 고차원적인 정보로 변환하여, 문장이나 단어의 의미를 더 잘 표현할 수 있도록 도움.
- 즉, 정보를 종합하고, 잘 표현할 수 있도록 도와주는 역할.


## 8.3 Transformer model

### Transformer – Position-wise Feed forward network



## 8.3 Transformer model

### Transformer – Decoder



실제 입력 결과를 이용하여 출력 결과를 만들어주는 부분.

- decoder에서는 encoder와 달리 순차적으로 결과를 만들어내야 하기 때문에 self-attention을 변형해야 함.
- 따라서 Masking을 해주어서 이를 통해, 현재 시점 보다 뒤에 있는 position에 attention을 주지 못하게 한다. 즉, 현재 시점에 대한 예측은 미리 알고 있는  $t-1$  시점의 output들에만 의존.
- 예시를 보면, a를 예측할 때는 a이후에 있는 b,c에는 attention이 주어지지 않고 b를 예측할 때는 b이전에 있는 a만 attention이 주어질 수 있음. 이후에 있는 c는 attention이 주어지지 않음.

## 8.3 Transformer model

### 요약: Transformer model

1. 입력 임베딩(Input Embedding):
  - 문장의 단어들을 고정된 크기의 벡터로 변환.
  - 이 벡터들은 단어의 의미를 수치적으로 나타내며, 모델의 첫 번째 계층으로 입력.
2. 포지셔널 인코딩(Positional Encoding):
  - 각 단어 벡터에 위치 정보를 추가하여, 모델이 단어의 순서와 문장 내 위치를 인식할 수 있게 함.
  - 이는 데이터의 순서 특성을 보존.
3. 셀프 어텐션(Self-Attention):
  - 각 단어가 문장 내 다른 모든 단어와 어떻게 관련되는지를 평가하여, 문맥적 의미를 포착.
  - 이를 통해 모델은 각 단어의 중요도와 연관성을 파악하고 적절히 가중치를 부여.
4. 멀티-헤드 어텐션(Multi-Head Attention):
  - 셀프 어텐션을 여러 번 병렬로 수행하여, 다양한 관점에서 단어 간의 관계를 분석.
  - 이를 통해 모델은 더욱 정확하고 다양한 정보를 추출 가능.

## 8.3 Transformer model


### 요약: Transformer model

5. 피드 포워드 네트워크(Feed-Forward Network, FFN):
  - 셀프 어텐션을 통해 얻은 정보를 추가적으로 처리하고, 문장의 의미를 더욱 강화 및 정보 압축.
  - 일반적으로 선형 변환과 비선형 활성화 함수로 구성.
6. 정규화(Layer Normalization):
  - 각 계층의 출력을 정규화하여 학습 과정을 안정화하고, 학습 속도를 개선.
7. 출력(Output Layer):
  - 모델의 마지막 부분에서, 최종적으로 얻은 벡터를 사용하여 필요한 작업(예: 번역, 요약, 분류 등)에 맞는 출력을 생성.
8. 인코더와 디코더(Encoder and Decoder):  
트랜스포머는 인코더와 디코더로 구성.
  - 인코더: 입력 문장을 처리하고, 중간 표현을 생성합니다.
  - 디코더: 인코더의 출력과 추가 입력(예: 이전 단어)을 사용하여 최종 출력(예: 번역된 문장)을 생성.

## 8.3 Transformer model


### 다양한 학습 기법

- Optimizer (Adam)
- Residual Connection
- Label Smoothing
- Dropout
- Learning rate scheduling




<Optimizing>


$$H(x) = x + F(x)$$



<Residual Connection>



(a) Standard Neural Net



(b) After applying dropout.


<Dropout>



## 8.3 Transformer model

다양한 학습 기법

### CPU와 GPU의 연산



- Transformer 연산을 이용하여 텍스트를 병렬로 처리하면 한꺼번에 많은 양을 읽을 수 있네?

## 8.4 BERT

### BERT

#### BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Jacob Devlin   Ming-Wei Chang   Kenton Lee   Kristina Toutanova  
Google AI Language  
{jacobdevlin, mingweichang, kentonl, kristout}@google.com

##### Abstract

We introduce a new language representation model called **BERT**, which stands for **B**idirectional **E**ncoder **R**epresentations from **T**ransformers. Unlike recent language representation models (Peters et al., 2018a; Radford et al., 2018), BERT is designed to pre-train deep bidirectional representations from unlabeled text by jointly conditioning on both left and right context in all layers. As a result, the pre-trained BERT model can be fine-tuned with just one additional output layer to create state-of-the-art models for a wide range of tasks, such as question answering and language inference, without substantial task-specific architecture modifications.

BERT is conceptually simple and empirically powerful. It obtains new state-of-the-art results on eleven natural language processing tasks, including pushing the GLUE score to 80.5% (7.7% point absolute improvement), MultiNLI accuracy to 86.7% (4.6% absolute improvement), SQuAD v1.1 question answering Test F1 to 93.2 (1.5 point absolute improvement) and SQuAD v2.0 Test F1 to 83.1 (5.1 point absolute improvement).

There are two existing strategies for applying pre-trained language representations to downstream tasks: *feature-based* and *fine-tuning*. The feature-based approach, such as ELMo (Peters et al., 2018a), uses task-specific architectures that include the pre-trained representations as additional features. The fine-tuning approach, such as the Generative Pre-trained Transformer (OpenAI GPT) (Radford et al., 2018), introduces minimal task-specific parameters, and is trained on the downstream tasks by simply fine-tuning *all* pre-trained parameters. The two approaches share the same objective function during pre-training, where they use unidirectional language models to learn general language representations.

We argue that current techniques restrict the power of the pre-trained representations, especially for the fine-tuning approaches. The major limitation is that standard language models are unidirectional, and this limits the choice of architectures that can be used during pre-training. For example, in OpenAI GPT, the authors use a left-to-right architecture, where every token can only attend to previous tokens in the self-attention layers



BERT: Pre-training of deep bidirectional transformers for language (2018)

## 8.4 BERT

### BERT

하이 -> 헬로우  
나이스투미팅 -> 유튜  
땡큐 -> 유어웰컴  
아임쏘리 -> 아임파인  
웨어아유프롬 -> 아임프롬서울  
...



처음부터 무식하게 외우는 것은 어렵고 오래 걸림

## 8.4 BERT

### BERT



Hi -> Hello  
Nice to meet you -> You too  
Thank you -> You're welcome  
I'm sorry -> I'm fine  
Where are you from -> I'm from Seoul  
...




먼저 언어의 기본을 익히고 문장을 외우면 더 빠르고 효과적

# 8.4 BERT


## BERT

1 - **Semi-supervised** training on large amounts of text (books, wikipedia..etc).

The model is trained on a certain task that enables it to grasp patterns in language. By the end of the training process, BERT has language-processing abilities capable of empowering many models we later need to build and train in a supervised way.




2 - **Supervised** training on a specific task with a labeled dataset.



## 8.4 BERT

### BERT





- 학습이 끝난 모델의 마지막에 해당 문제를 위한 간단한 신경망 레이어를 붙여서 추가로 fine-tuning.
- 이미 사전훈련을 통해 언어모델이 만들어졌기 때문에 데이터셋이 적어도 학습이 쉽게 이루어짐.

## 8.4 BERT

### BERT

- 트랜스포머의 인코더만 사용
- BERT Base
  - 12개의 트랜스포머 블록
- BERT Large
  - 24개의 트랜스포머 블록



## 8.4 BERT

### BERT

- BooksCorpus
  - 8억 단어
- Wikipedia
  - 25억 단어




**WIKIPEDIA**  
The Free Encyclopedia




# 8.4 BERT

## BERT Pre-training task 1 : Masked Language Model(MLM)




# 8.4 BERT

## BERT Pre-training task 1 : Masked Language Model(MLM)




# 8.4 BERT

## BERT Pre-training task 2 : Next Sentence prediction




# 8.4 BERT


## BERT fine-tuning




(a) Sentence Pair Classification Tasks:  
MNLI, QQP, QNLI, STS-B, MRPC,  
RTE, SWAG



(b) Single Sentence Classification Tasks:  
SST-2, CoLA



(c) Question Answering Tasks:  
SQuAD v1.1



(d) Single Sentence Tagging Tasks:  
CoNLL-2003 NER

## 8.4 BERT

### BERT results

| System                | MNLI-(m/mm)<br>392k | QQP<br>363k | QNLI<br>108k | SST-2<br>67k | CoLA<br>8.5k | STS-B<br>5.7k | MRPC<br>3.5k | RTE<br>2.5k | Average<br>- |
|-----------------------|---------------------|-------------|--------------|--------------|--------------|---------------|--------------|-------------|--------------|
| Pre-OpenAI SOTA       | 80.6/80.1           | 66.1        | 82.3         | 93.2         | 35.0         | 81.0          | 86.0         | 61.7        | 74.0         |
| BiLSTM+ELMo+Attn      | 76.4/76.1           | 64.8        | 79.9         | 90.4         | 36.0         | 73.3          | 84.9         | 56.8        | 71.0         |
| OpenAI GPT            | 82.1/81.4           | 70.3        | 88.1         | 91.3         | 45.4         | 80.0          | 82.3         | 56.0        | 75.2         |
| BERT <sub>BASE</sub>  | 84.6/83.4           | 71.2        | 90.1         | 93.5         | 52.1         | 85.8          | 88.9         | 66.4        | 79.6         |
| BERT <sub>LARGE</sub> | <b>86.7/85.9</b>    | <b>72.1</b> | <b>91.1</b>  | <b>94.9</b>  | <b>60.5</b>  | <b>86.5</b>   | <b>89.3</b>  | <b>70.1</b> | <b>81.9</b>  |

<모든 task 에 대하여 SOTA 달성>

## 8.4 BERT


### BERT ablation studies

| Tasks                | Dev Set         |               |               |                |               |
|----------------------|-----------------|---------------|---------------|----------------|---------------|
|                      | MNLI-m<br>(Acc) | QNLI<br>(Acc) | MRPC<br>(Acc) | SST-2<br>(Acc) | SQuAD<br>(F1) |
| BERT <sub>BASE</sub> | 84.4            | 88.4          | 86.7          | 92.7           | 88.5          |
| No NSP               | 83.9            | 84.9          | 86.5          | 92.6           | 87.9          |
| LTR & No NSP         | 82.1            | 84.3          | 77.5          | 92.1           | 77.8          |
| + BiLSTM             | 82.1            | 84.1          | 75.7          | 91.6           | 84.9          |

- 1.No NSP: Pre-train시 MLM은 사용하지만, 다음 문장 예측 (NSP)를 없앤 모델
- 2.LTR & No NSP : MLM 대신 Left-to-Right (LTR) 을 사용하고, NSP도 없앤 모델

## 8.4 BERT

BERT 모델의 의의. 사.전.학.습의 강력함.



- 학습 데이터와 모델이 커지니 할 수 있는 일이 많아짐을 증명
- 이후 열린 사전학습 전성시대

## 8.5 Pre-trained model?

- 사전학습 모델은 대량의 데이터를 사용하여 사전에 학습된 인공지능 모델.
- 이 모델은 일반적으로 텍스트, 이미지, 음성 등 다양한 유형의 데이터를 활용하여 훈련.
- 사전학습 모델은 일반적으로 큰 규모의 신경망으로 구성되어 있으며, 많은 수의 매개변수를 조절하여 다양한 작업에서 유용하게 사용될 수 있도록 학습.



# Hugging Face



## 8.5 Pre-trained model

---



**Hugging Face**

- 사전학습 모델의 공개로 인한 AI업계의 엄청난 성장
- GitHub, Hugging Face에서 검색 및 이용 가능

## 8.5 Pre-trained model



- 오픈소스 사전학습 모델의 공개로 인한 AI업계의 엄청난 성장
- 현재도 일부 생성형AI는 소스코드, 학습된 신경망 open.

**감사합니다**