

모두를 위한 딥러닝 (이미지처리편)

경북대학교 IT교육센터

허 찬

차시(모듈)	차시별 주제	학습내용
1	딥러닝을 이용한 이미지 처리	이미지 처리의 이해 다양한 이미지처리의 응용 분야에 대한 이해
2	특징 추출의 이해	이미지 데이터 전처리 기법의 이해 이미지 특징 추출의 이해 및 실습 딥러닝을 이용한 학습 및 추론 과정의 이해
3	Convolution Neural Network	합성곱 신경망의 이해
4	CNN 모델의 이해	다양한 CNN 모델의 이해 딥러닝의 여러가지 요소 이해
5	CNN을 이용한 분류 모델 실습	CNN을 이용한 이미지 분류 모델 실습
6	전이 학습 모델의 이해	전이 학습의 이해 전이학습을 이용한 이미지 처리 모델 실습
7	객체 인식 모델의 이해	다양한 객체 인식 모델의 이해 Semantic segmentation (U-Net)의 이해
8	Transformer 기반 이미지 처리 모델 1	Attention과 Transformer의 이해
9	Transformer 기반 이미지 처리 모델 2	Transformer 기반 이미지 처리 모델 (ViT)의 이해
10	이미지 생성 모델의 이해	최신 이미지 생성 모델의 이해 오토인코더의 이해 및 실습
11	최신 이미지 처리 기술의 이해	최신 컴퓨터비전 모델의 이해 비디오 처리의 이해


9.1 Vision transformer

Attention for vision

Attention

- Attention

- ✓ The process by which we select a subset from all of the available information for future processing
- ✓ Targeting faces, words, images, etc
- ✓ Attend to more informative objects



(a)


Mona Lisa is a portrait painted by Leonardo da Vinci.

Mona Lisa is a portrait painted by Leonardo da Vinci.




9.1 Vision transformer

Vision Transformer




An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (A. Dosovitskiy et al. ICLR 2021)


9.1 Vision transformer





Transformer Encoder



9.1 Vision transformer



9.1 Vision transformer



9.1 Vision transformer

이미지 패치 분할

- ViT는 이미지를 직접 처리하는 대신, 이미지를 작은 패치(patch)로 분할.
- 각 패치는 일반적으로 16×16 픽셀 크기, 이러한 패치들을 펼쳐서 벡터화.
- 예를 들어, 224×224 크기의 이미지를 16×16 패치로 분할하면, 총 $14 \times 14 = 196$ 개의 패치가 생성.

패치 임베딩

- 각 패치 벡터는 선형 변환을 통해 고차원 임베딩으로 변환.
- 패치 임베딩은 Transformer 모델의 입력으로 사용되며, 이는 텍스트 Transformer 모델에서의 단어 임베딩과 유사한 역할을 합니다.

위치 임베딩


- Transformer 모델은 순서를 인식하지 못하기 때문에, 각 패치의 위치 정보를 제공하기 위해 위치 임베딩을 추가.
- 위치 임베딩은 패치 임베딩에 더해져 모델이 패치의 상대적 위치를 인식 가능.

이후는 Transformer와 거의 비슷함!


9.1 Vision transformer

CNN vs ViT

 Receptive Field



Convolution of CNN



Attention of Vision Transformer

9.1 Vision transformer

CNN vs ViT

<장점>

- Transformer 구조를 거의 그대로 사용하기 때문에 확장성이 좋음. 기존 attention 기반의 모델들은 이론적으로 좋음에도 불구하고 특성화된 attention 패턴 때문에 효과적으로 다른 네트워크에 확장하기가 어려움을 겪음.
- Transformer가 large scale 학습에 우수한 성능이 있다는 것이 검증되었기 때문에 이와 같은 효과를 그대로 얻을 수 있음.
- 많은 양의 데이터로 학습시켰을 경우 전이학습 성능이 좋음.

9.1 Vision transformer

CNN vs ViT

<단점>

- Inductive bias 의 부족으로 인해 CNN보다 데이터가 많이 요구.
- **Inductive bias**는 모델이 처음 보는 입력에 대한 출력을 예측하기 위하여 사용하는 추가적인 가정. 예를 들어, CNN의 경우 translation equivariance, locality를 가정.
 - **Translation equivariance** : 입력 위치가 변하면 출력 또한 위치가 변한다는 것을 가정
 - **Locality** : Convolution 연산을 할 때, 이미지 전체에서 Conv 필터가 이미지의 일부분만 보게 되는데, 이 특정 영역만을 보고 Conv 필터가 특징을 추출할 수 있다는 것을 가정.
- 반면, Transformer 모델은 attention 구조만을 사용. Attention은 CNN과 같이 local receptive field를 보는 것이 아니라, 데이터 전체를 보고 attention할 위치를 정하는 메커니즘이기 때문에, 이 패턴을 익히기 위해서 CNN 보다 더 많은 데이터를 필요. **불충분한 데이터 양으로 학습을 하게 되면 일반화 성능이 떨어지게 됨.**
- ImageNet과 같은 Mid-size 데이터셋으로 학습 시, ResNet보다 낮은 성능을 보임.
- 논문에서는 ImageNet-21K나 JFT-300M 데이터셋 처럼 14M~300M 크기의 large scale 데이터 셋으로 사전 학습을 하고 CIFAR100으로 transfer learning을 하였을 때, 높은 정확도를 보여줌.

9.2 다양한 Vision transformer

Swin Transformer

- Liu, Ze, et al. "Swin transformer: Hierarchical vision transformer using shifted windows." Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021.
 - ✓ Architecture





Figure 3. (a) The architecture of a Swin Transformer (Swin-T); (b) two successive Swin Transformer Blocks (notation presented with Eq. (3)). W-MSA and SW-MSA are multi-head self attention modules with regular and shifted windowing configurations, respectively.

9.2 다양한 Vision transformer

Swin Transformer

- Liu, Ze, et al. "Swin transformer: Hierarchical vision transformer using shifted windows." Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021.

- ✓ Shifted Window based Self-Attention



- ✓ Relative position bias

- Add a relative position bias $B \in \mathbb{R}^{(2M-1) \times (2M-1)}$: relative position of patches within window
- $$Attention = softmax\left(\frac{Q \cdot K^T}{\sqrt{D_h}} + B\right) V$$

9.2 다양한 Vision transformer

Swin Transformer V2

- Liu, Ze, et al. "Swin transformer v2: Scaling up capacity and resolution." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022.

- 여러가지 모듈을 개선한 모델

- ✓ Post normalization

- Layer normalization after attention block

- ✓ Scaled cosine attention


- $$\text{Sim}(q_i, k_j) = \frac{\cos(q_i, k_j)}{\tau} + B_{ij}$$

- ✓ Continuous relative position bias

- $B(\Delta x, \Delta y) = \mathcal{G}(\Delta x, \Delta y)$, $\mathcal{G}$ is a 2-layer MLP with a RELU

- ✓ Log-spaced coordinates


- $\widehat{\Delta x} = \text{sign}(x) \cdot \log(1 + |\Delta x|)$
- $\widehat{\Delta y} = \text{sign}(y) \cdot \log(1 + |\Delta y|)$




9.2 다양한 Vision transformer

MobileViT

- Mehta, Sachin, and Mohammad Rastegari. "Mobilevit: light-weight, general-purpose, and mobile-friendly vision transformer." arXiv preprint arXiv:2110.02178 (2021).
- 경량화된 모듈을 제안



(a) Standard visual transformer (ViT)




(b) MobileViT. Here, $\text{Conv-}n \times n$ in the MobileViT block represents a standard $n \times n$ convolution and MV2 refers to MobileNetV2 block. Blocks that perform down-sampling are marked with $\downarrow 2$.

9.2 다양한 Vision transformer

MobileViT

- Mehta, Sachin, and Mohammad Rastegari. "Mobilevit: light-weight, general-purpose, and mobile-friendly vision transformer." arXiv preprint arXiv:2110.02178 (2021).
 - ✓ MobileViT Block & Global Computation
 - Blue pixels: encode information about the neighboring pixels using **convolution**
 - Red pixels: encodes information from all pixels using **self attention**





9.2 다양한 Vision transformer

MobileViT V2

- Mehta, Sachin, and Mohammad Rastegari. "Separable Self-attention for Mobile Vision Transformers." arXiv preprint arXiv:2206.02680 (2022).

✓ Architecture

- Multi-Head Self-Attention -> Separable Self-Attention
- Remove skip-connection and fusion block in the MobileViT block



감사합니다