


모두를 위한 딥러닝 (이미지처리편)

경북대학교 IT교육센터

허 찬


차시(모듈)	차시별 주제	학습내용
1	딥러닝을 이용한 이미지 처리	이미지 처리의 이해 다양한 이미지처리의 응용 분야에 대한 이해
2	특징 추출의 이해	이미지 데이터 전처리 기법의 이해 이미지 특징 추출의 이해 및 실습 딥러닝을 이용한 학습 및 추론 과정의 이해
3	Convolution Neural Network	합성곱 신경망의 이해
4	CNN 모델의 이해	다양한 CNN 모델의 이해 딥러닝의 여러가지 요소 이해
5	CNN을 이용한 분류 모델 실습	CNN을 이용한 이미지 분류 모델 실습
6	전이 학습 모델의 이해	전이 학습의 이해 전이학습을 이용한 이미지 처리 모델 실습
7	객체 인식 모델의 이해	다양한 객체 인식 모델의 이해 Semantic segmentation (U-Net)의 이해
8	Transformer 기반 이미지 처리 모델 1	Attention과 Transformer의 이해
9	Transformer 기반 이미지 처리 모델 2	Transformer 기반 이미지 처리 모델 (ViT)의 이해
10	이미지 생성 모델의 이해	최신 이미지 생성 모델의 이해 오토인코더의 이해 및 실습
11	최신 이미지 처리 기술의 이해	최신 컴퓨터비전 모델의 이해 비디오 처리의 이해

11.1 최신 컴퓨터비전 모델




A ConvNet for the 2020s (CVPR 2022, Meta)

11.1 최신 컴퓨터비전 모델



- CNN > ViT로 넘어가려는 흐름
- 하지만 CNN을 제대로 이해한걸까?
- ViT를 학습시키기 위해 여러 학습 방법론을 적용한 것과 비슷한 방법으로 CNN을 다양한 학습
- 기존 CNN을 가지고도 (잘 학습하면) ViT의 성능을 넘을 수 있다!

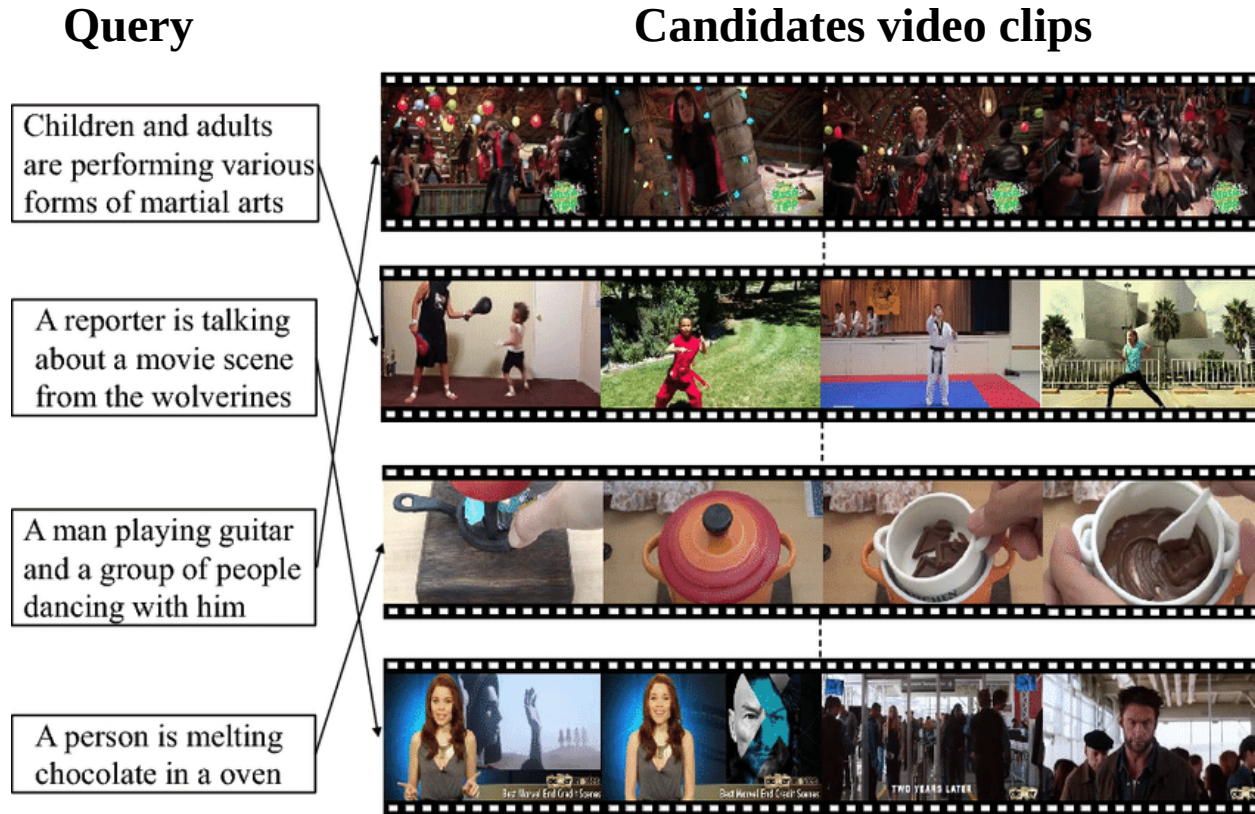
딥러닝을 이용한 패턴 인식




1. 추출된 특징을 바탕으로 (SIFT, HOG, DNN/CNN output...)
2. 머신러닝 분류기를 사용

<딥러닝을 응용하는 경우 이 특징추출을 어떻게 정의하는지가 굉장히 중요!!!>

11.2 Deep learning in Vision - applications (Video)




- Retrieve appropriate video clip with text-form query



- Embedding-based approach

11.2 Deep learning in Vision - applications

Video representation




- Using CNN and pooling module for making Video representation (video clip) – Red box

Learning joint representations of videos and sentences with web image search (ECCV 2016)

11.2 Deep learning in Vision - applications


Video representation



- 특징 추출을 위해 비디오 프레임의 2D CNN과 비디오의 3D CNN을 동시에 사용

Learning Joint Embedding with Multimodal Cues for Cross-Modal Video-Text Retrieval (ICMR 2018)


11.2 Deep learning in Vision



- 계층적으로 CNN + RNN 계열 모델링을 이용하여 특징 추출

Dual Encoding for Video Retrieval by Text (CVPR 2019/TPAMI 2021)


11.2 Deep learning in Vision



- 비디오 프레임을 CNN 특징추출 + LSTM 을 이용하여 정의.

Attention-Based Relation Reasoning Network for Video-Text Retrieval (ICME 2021)


11.2 Deep learning in Vision



- CNN과 객체인식모듈을 함께 사용하여 비디오의 특징을 추출하는데 사용.

FeatInter: Exploring fine-grained object features for video-text retrieval (Neurocomputing 2022)


11.2 Deep learning in Vision



- 시각적인 이미지 뿐 아니라 다양한 특징추출 모듈들을 이용하여 비디오의 특징을 정의

Use What You Have: Video Retrieval Using Representations From Collaborative Experts (BMVC 2019)


11.2 Deep learning in Vision



- 다양한 특징추출 모듈들을 이용하여 비디오의 특징을 정의

Learning a Text-Video Embedding from Incomplete and Heterogeneous Data (HAL 2019)


11.2 Deep learning in Vision



- 다양한 특징추출 모듈들을 이용하여 비디오의 특징을 정의
- 이러한 과정에서 transformer 구조를 활용

Multi-modal Transformer for Video Retrieval (ECCV 2020)


11.2 Deep learning in Vision



- 하나의 텍스트를 lstm, gru, bow 등을 통해 다양하게 벡터를 얻어 합친 것을 text representation으로 취급.

SEA: Sentence Encoder Assembly for Video Retrieval by Textual Queries (IEEE Multimedia 2020)

11.2 Deep learning in Vision



- 최근에는 대조학습 기반의 모델들이 특징을 표현하기 위해 사용.


$$\mathcal{L}(A, P, N) = \max\left(\|f(A) - f(P)\|^2 - \|f(A) - f(N)\|^2 + \alpha, 0\right) \quad (\text{Triplet loss})$$

$$\mathcal{L}_{\text{rank}}(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^t) = \sum_{(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^t)} \{ \max[0, \lambda - S(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^t) + S(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^{t-})] + \max[0, \lambda - S(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^t) + S(\mathbf{v}_{m2}^t, \mathbf{s}_{m2}^{t-})] \}, \quad (\text{Bidirectional triplet ranking loss})$$

VSE++: Improving Visual-Semantic Embeddings with Hard Negatives (BMVC 2018 spotlight)

Multi-Modal Memory Enhancement Attention Network for Image-Text Matching (IEEE ACCESS 2020)

11.2 Deep learning in Vision




- 최근에는 대조학습 기반의 모델들이 사용.


Disentangled Representation Learning for Text-Video Retrieval (Arxiv 2022)

11.3 Deep learning in multimodal data


Unimodal AI model



Multimodal AI model



11.3 Deep learning in multimodal data



- 동시에 여러 input을 transformer에 주고 관계를 학습

11.3 Deep learning in multimodal data



What would happen if
the strings were cut?




The balloons would
fly away.


GPT-4

11.3 Deep learning in multimodal data

(1) Contrastive pre-training



(2) Create dataset classifier from label text




- Awesome model made by OpenAI
- Using 14 Million image-text pairs for training model

CLIP model


(2021) Learning Transferable Visual Models From Natural Language Supervision (CLIP)

11.3 Deep learning in multimodal data

(1) Contrastive pre-training



(2) Create dataset classifier from label text



(3) Use for zero-shot prediction

- 이미지와 텍스트가 어떤 공간에서 (semantic space) 유사한 이미지-텍스트 페어가 같은 의미를 가지도록 학습

CLIP model

(2021) Learning Transferable Visual Models From Natural Language Supervision (CLIP)

DEEP LEARNING



감사합니다